

韩卫雪,周亚同,池越.基于深度学习卷积神经网络的地震数据随机噪声去除[J].石油物探,2018,57(6):862-869

HAN Weixue,ZHOU Yatong,CHI Yue.Deep learning convolutional neural networks for random noise attenuation in seismic data [J].Geophysical Prospecting for Petroleum,2018,57(6):862-869

基于深度学习卷积神经网络的地震数据随机噪声去除

韩卫雪,周亚同,池 越

(河北工业大学电子信息工程学院,天津 300401)

摘要:为了有效去除地震数据随机噪声,提出了一种基于卷积神经网络(CNN)的地震数据随机噪声去除算法。算法的关键在于构建一个适用于地震数据去噪的 CNN,包含输入层、卷积层、激活层、输出层等。该 CNN 以含噪地震数据作为输入层,由多个卷积层提取并处理地震数据,激活层采用修正线性单元(ReLU)获取地震数据波动特征,再借助归一化层加速网络训练收敛速度。CNN 通过残差学习获得随机噪声并由网络输出层输出。分别采用小波变换、双树复小波变换、曲波变换以及 CNN 对实际叠前海上地震数据、叠后陆地数据及复杂陆地叠后数据进行去噪,实验结果表明,CNN 能有效去除随机噪声,且与常规去噪算法相比具有更强的去噪能力,验证了算法的可行性和有效性。

关键词:卷积神经网络;深度学习;地震数据;随机噪声;去噪

中图分类号:P631

文献标识码:A

文章编号:1000-1441(2018)06-0862-08

DOI:10.3969/j.issn.1000-1441.2018.06.008

Deep learning convolutional neural networks for random noise attenuation in seismic data

HAN Weixue,ZHOU Yatong,CHI Yue

(School of Electronics and Information Engineering, Hebei University of Technology, Tianjin 300401, China)

Abstract: In order to effectively remove the random noise in seismic data, a denoising algorithm based on a convolutional neural network (CNN) within the deep learning framework is proposed. The key requirement of the algorithm is to construct a CNN that is suitable for seismic data denoising, which includes the input layer, convolution layers, activation layer, and output layer. The CNN uses noisy seismic data as inputs, extracts and processes the seismic data via the multiple convolution layers, extracts the fluctuation characteristics of the data using the rectified linear units in the activation layer, accelerates the training convergence using the normalization layer, and finally uses residual learning to obtain the random noise as the output via the network output layer. Tests using pre-stack marine seismic data, post-stack seismic land data, and complex post-stack seismic land data illustrated the feasibility and effectiveness of the CNN for seismic denoising. Furthermore, the CNN outperformed some traditional denoising algorithms, such as the wavelet, dual-tree complex wavelet, and curvelet transforms in random noise attenuation.

Keywords: convolutional neural networks, deep learning, seismic data, random noise, denoising

地震数据去噪是提高地震资料信噪比的重要步骤,去噪效果好坏直接影响后续地震数据处理的质量^[1]。机器学习技术发展迅猛,作为机器学习的一个分支,深度学习和卷积神经网络在 AlphaGo 人机对

弈^[2]和网络大数据分析^[3]等领域取得了巨大的成就。如何利用深度学习及 CNN 的强大功能去除地震数据噪声,是地震数据处理领域面临的课题之一。

常见的地震数据去噪方法有: $f-k$ 域滤波、 $f-x$

收稿日期:2017-09-06;改回日期:2018-07-05。

作者简介:韩卫雪(1991—),女,硕士在读,主要研究方向为地震信号处理。Email:784191663@qq.com

通讯作者:周亚同(1973—),男,教授,博士生导师。主要研究方向为机器学习及应用、地震信号处理等。

基金项目:国家自然科学基金(51475136)、河北省引进留学人员资助项目(CL201707)和河北省研究生创新资助项目(CXZZSS2018012)共同资助。
This research is financially supported by the National Natural Science Foundation of China (Grant No.51475136), Returned Oversea Scholars Foundation of Hebei Province (Grant No.CL201707) and Innovation Project for Graduate Student of Hebei Province (Grant No.CXZZSS2018012).

域预测滤波、小波变换去噪、曲波变换、低秩约束去噪等。中原敏明等^[4]在频率波数域内设计不同的滤波器,对地震数据进行 $f-k$ 二维滤波。康冶等^[5]提出一种 $f-x$ 域拟线性变换并用于去噪。刘婷婷等^[6]将 $f-x$ 域 EMD 和多道奇异谱分析结合用于去除地震数据随机噪声。张华等^[7]研究了地震数据去噪时小波基的选择问题。王姣等^[8]提出了一种改进的小波阈值随机噪声去除算法。LI 等^[9]提出基于小波高阶相关叠加的混合去噪算法并用于去除随机和相干噪声。孙成禹等^[10]提出基于独立分量分析基的地震随机噪声压制。刘成明等^[11]将 Shearlet 变换用于地震随机噪声压制。CHEN 等^[12]和 ZHOU 等^[13]分别采用经验化和结构化矩阵低秩约束实施去噪等。刘伟等^[14]实现了基于压缩感知和 TV 准则约束的地震资料去噪。上述去噪算法虽然取得了较好的应用效果,但在去噪性能或去噪效率方面仍然存在一些不足,因此探究新的去噪算法具有重要意义。

CNN 是在人工神经网络基础上发展起来的。早在二十多年前,人工神经网络就已经应用于地震数据处理。例如吴剑华等^[15]提出一种基于神经网络的地震数据去噪算法,张范民等^[16]利用人工神经网络对地震相进行识别等。但人工神经网络存在训练速度慢、容易出现过拟合或者陷入局部最小值等不足,而 CNN 具有并行处理能力强、运行速度快、自适应性和容错性良好等优点。CNN 具有多种结构,例如 AlexNet 和 VGGNet 等^[17-18]。同时 CNN 在信号去噪^[19-20]、人脸识别^[21]以及语音识别^[22]等领域都已经

取得显著的应用效果。但是 CNN 被用于地震信号去噪的文献则较少。

基于以上考量,本文构建一种适合于地震信号去噪的 CNN,并将之用于地震数据随机噪声的去除。该 CNN 由输入层、卷积层、激活层、归一化层、输出层组成,其中激活层选用修正线性单元(ReLU)^[17]作为激活函数,归一化层采用批归一化(BN)^[23],以原始含噪地震数据作为输入,以随机噪声作为输出。CNN 的训练过程是首先初始化网络,然后利用原始地震数据训练集及其对应的含噪数据集进行网络训练,直至得到网络结构的最优参数。网络的去噪过程为:将含噪地震数据输入训练完成的网络,利用残差学习得到与输入层对应的残差数据,该残差即为所含随机噪声。最后通过实际叠前海上数据、叠后陆地数据以及复杂陆地叠后地震数据进行去噪实验,验证本文去噪算法的可行性,并且与其它几种常见去噪算法相比,验证本文算法的去噪效果。

1 深度学习卷积神经网络简介

传统神经网络,如 BP 神经网络或径向基神经网络等,每层的神经元节点是全连接的,而在 CNN 中各节点局部连接,并且同一层的某些神经元的连接权重共享,这种结构更类似于生物神经网络,因此 CNN 网络模型复杂度更低,权值数量更少,这对于深度学习有重要意义^[24]。典型的 CNN 的拓扑结构如图 1 所示。




图 1 典型的卷积神经网络拓扑结构

CNN 的典型网络拓扑结构通常包括输入层、卷积层、池化层、全连接层及输出层等。待处理数据作为网络输入层;卷积层作为特征提取层,每个神经单元的输入与前一层的局部感受野相连接,并提取局部特征,从而确定该局部特征与其它特征间的位置关系;池化层作为特征映射层,每个特征映射为一个平面,上面每个神经单元的权重相同;全连接层将每个局部特征进行组合,从而得到全局特征;输出层则需要根据网络的具体用途和网络结构确定。CNN 因为具有局部连接和权值共享两个特点,有效减少了网络

中的自由参数,提高了网络训练的效率,有利于提升地震数据去噪效率。

2 基于 CNN 的地震数据随机噪声去除

地震数据去噪是从含噪地震数据中去除噪声,恢复原始地震数据,具体公式如下:

$$x = y + v \quad (1)$$

式中: x 为含噪地震数据; y 为不含噪原始地震数据; v 为所含噪声。地震数据去噪的最终目标是获得原

始地震数据的一个估计 y_0 , 且 $y_0 \approx y$ 。

本文借鉴原本用于图像去噪的 CNN 结构^[19], 构建一种用于去除地震数据随机噪声的 CNN。CNN 最终能输出随机噪声 $R(x) \approx v$, 用含噪地震数据 x 减去随机噪声 $R(x)$ 即可获得原始地震数据的估计, 即 $y_0 = x - R(x)$ 。由含噪地震数据得到的随机噪声估计值与其期望值的均方差平均值为^[19]:

$$\psi(\rho) = \frac{1}{2M} \sum_{i=1}^M \|R(x_i; \rho) - (x_i - y_i)\|_F^2 \quad (2)$$

式中: $x_i (i = 1, 2, \dots, M)$ 为 M 个含噪地震数据训练样本; $y_i (i = 1, 2, \dots, M)$ 为 M 个不含噪原始地震数据训练样本; $\|\cdot\|_F = \sqrt{\sum (\cdot)^2}$ 是 Frobenius 范数。在 CNN 训练过程中, 若将 (2) 式作为残差计算方程, 可得到 CNN 的训练参数 ρ , 通过训练不断优化该参数, 从而尽可能避免特征提取过程中有效信息的损失。

2.1 地震数据去噪 CNN 的隐藏层

CNN 隐藏层通常包括卷积层、激活层、归一化层。卷积层是多个特征面的组合, 每个特征面上有多个神经元, 而每个神经元通过卷积核与上一层的特征面局部连接, 其中卷积核是一个权值矩阵。卷积层的主要作用是提取地震特征, 其每一种输出的特征 g_j 有:

$$g_j^l = f\left(\sum_{k \in \Gamma_j} g_k^{l-1} * W_{kj}^l + b_j^l\right) \quad (3)$$

式中: l 表示网络层数; g_j^l 为第 l 层的第 j 种特征; g_k^{l-1} 为第 $l-1$ 层的第 k 种特征, Γ_j 为选择输入的特征集合; W_{kj}^l 是连接两种特征的卷积核; b_j^l 为第 l 层的第 j 个特征对应的偏置; “*” 表示卷积操作。卷积核相当于若干个过滤器, 对应的滤波矩阵大小可设置为 1×1 或 3×3 等。

设 CNN 激活层的激活函数为 $f(\cdot)$, 本文采用修正线性单元 (ReLU) 作为激活函数, 对应的计算公式如下^[17]:

$$f(u) = \max(0, u) \quad (4)$$

ReLU 激活函数如图 2 所示, 图中横坐标 u 为 CNN 上一层网络的输出, 纵坐标 $f(u)$ 为当前网络层的输出。从图中可看出如果输入 $u > 0$, 则该激活函数输出与输入相等, 否则输出为 0, 因此输出不会因为输入的增大而趋于饱和。




图 2 CNN 所采用的 ReLU 激活函数

除了卷积层和激活层, 归一化层也是 CNN 隐藏层的一部分。本文的归一化层采用批归一化 (BN)^[23], 具体原理为: 在每一层网络输入时插入一个归一化层, 即将输入数据进行归一化处理, 之后再进入网络的下一层。在 CNN 网络中加入 BN, 能够减缓内部协变量转移, 降低对初始化权重的敏感度, 加快收敛的同时提高训练精度。

2.2 地震数据去噪 CNN 的具体拓扑结构

本文构建的 CNN 充分考虑了含噪地震数据与残差数据间的关系, 即不仅建立起由含噪地震数据到残差数据的映射, 而且也建立起由含噪地震数据到所含随机噪声的映射。图 3 为用于地震数据去噪的 CNN 具体拓扑结构。

如图 3 所示, 以含噪地震数据作为 CNN 的输入层。图中拓扑结构的第一部分为 C1: 第一层卷积层的卷积核大小为 3×3 , 经过卷积操作后得到 64 个特征映射。然后将特征数据的加权和输入激活层的激活函数 ReLU, 用于去除地震数据中的冗余, 尽可能

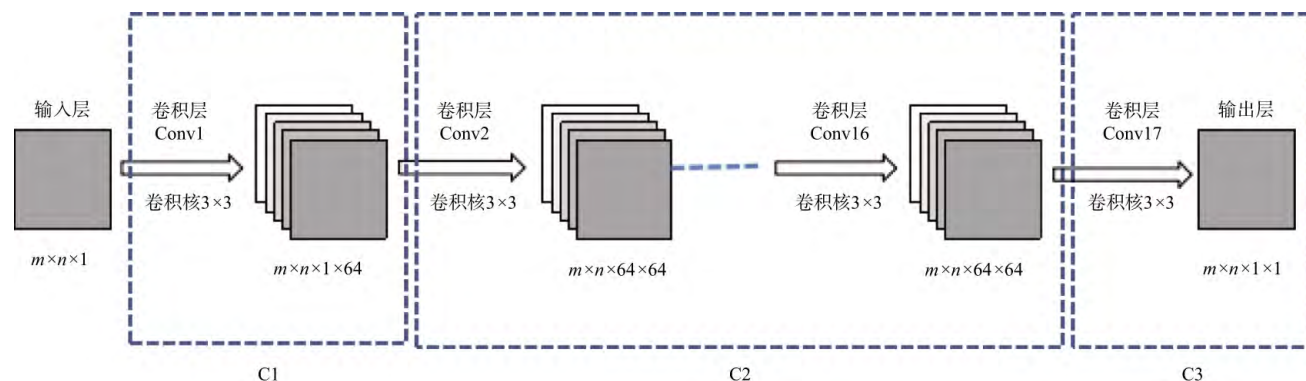


图 3 用于地震数据去噪的 CNN 具体拓扑结构

保留数据特征。图中拓扑结构的第二部分 C2 包括 15 个卷积层,每个卷积核大小均为 3×3 ,卷积操作后得到 64 个特征映射。与 C1 不同的是,C2 在卷积层与激活层之间添加了一个批归一化层,用于加快并稳定训练过程,提升去噪性能。图中拓扑结构的第三部分 C3 只包含一个卷积层,卷积核大小为 3×3 ,经过卷积操作得到 1 个特征映射,即为网络的输出层。

2.3 地震数据去噪 CNN 的特点

本文构建的 CNN 具有以下特点:

1) 网络输入和输出:通常网络的输出数据要求与输入数据大小相同,而如果特征数据与卷积核直接进行卷积操作,则会减小下一层特征数据的大小。为避免此种情况,本文在卷积操作前为特征数据扩展边界,直接补零至与输入数据相同大小,从而保证输出数据大小与输入数据一致,同时避免了边界数据伪影现象。

2) 残差学习^[25]:CNN 结合残差学习,构建一个由含噪地震数据到残差数据的非线性映射,平凡网络会因网络深度的增加导致训练误差随之增大,而加入残差学习的网络更加便于优化和控制误差范围。本文构建的 CNN 在增加网络深度时更易于提高训练精度,在地震数据去噪时也能够保留更多的数据波动特征。

3) 网络优化算法:本文采用自适应矩估计^[26]作为网络参数优化算法。该算法通过计算梯度的一阶矩估计和二阶矩估计,动态调整不同网络参数的学习速率,确定每次迭代学习速率的范围,使得网络参数变化平稳,网络本身能够自适应学习。并且该算法对内存需求较少,缓解了机器运行压力。

2.4 训练样本数量对 CNN 去噪性能影响的验证

本文以原始不含噪叠前和叠后地震数据集作为训练样本集,借助 MatConvNet 工具箱^[27]训练 CNN,

并使用图形处理单元(GPU)提高训练速度^[28]。实验在一台 CPU 主频为 2.40 GHz、GPU 为 NVIDIA GeForce 920 M、内存为 8 GB、Microsoft Windows 10 家庭中文版、64 位操作系统的个人笔记本电脑上进行,运行环境为 MATLAB(R2014b)。分别采用均方误差 M_{SE} 、输入信噪比 S_{NR_IN} 、输出信噪比 S_{NR_OUT} 、峰值信噪比 P_{SNR} 等指标定量衡量去噪算法的性能,上述指标的定义分别为:

$$M_{SE} = \frac{\|y - y_0\|_2}{N} \quad (5)$$

$$S_{NR_IN} = 20 \lg \left(\frac{\|y\|_2}{\|y - y_1\|_2} \right) \quad (6)$$

$$S_{NR_OUT} = 20 \lg \left(\frac{\|y\|_2}{\|y - y_0\|_2} \right) \quad (7)$$

$$P_{SNR} = 10 \lg \left[\frac{\max(y)^2}{M_{SE}} \right] \quad (8)$$

式中: S_{NR_IN} 为含噪地震信号的信噪比(输入信噪比); S_{NR_OUT} 为含噪地震信号去噪后的信噪比(输出信噪比); y 为不含噪原始地震数据; y_0 为去噪后的地震数据; y_1 为添加噪声后的地震数据; N 代表地震数据的采样点总数; $\|\cdot\|_2$ 代表 L2 范数。

利用 Marmousi 地震数据进行去噪实验,以检验训练样本数量对去噪性能的影响。选用的 Marmousi 数据共有 256 道,每道含 256 个采样点。在该数据中,人为添加均值为 0、噪声水平为幅值 9.8% 的加性高斯白噪声。设置两种去噪方案,方案一采用 400 个地震数据作为样本训练 CNN,每个地震数据的道数为 200,每道含 200 个采样点;方案二采用 200 个地震数据作为样本训练 CNN,每个地震数据的道数为 200,每道含 200 个采样点,两种方案均经过 50 历元(epoch),1 个 epoch 等于使用训练集中的全部样本训练一次。两种方案的 P_{SNR} 和 M_{SE} 比较如图 4

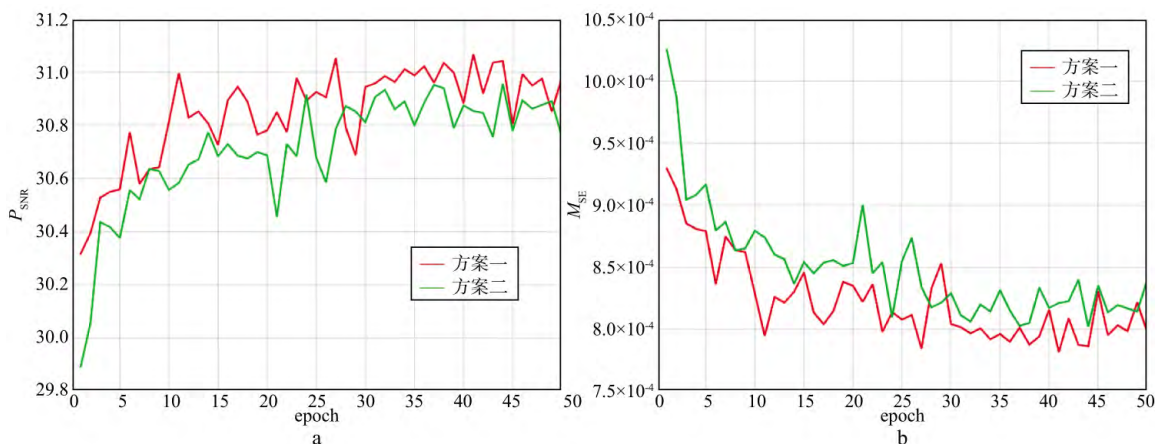


图4 不同数量的训练样本下 CNN 去噪性能对比

a P_{SNR} 对比; b M_{SE} 对比

所示。

图 4 表明方案一的峰值信噪比更高,均方误差更低,去噪性能优于方案二,这说明训练样本数量大一些,CNN 去噪性能会好一些。但在实际应用中并不是训练样本越多越好,因为随着训练样本增多,网络训练速度会变慢。对于本文算法而言,方案一已经能达到预期的去噪效果,因此在后文的去噪实验中训练样本的数量均选定为 400 个。

3 地震数据去噪实验结果及分析

下面采用本文去噪算法分别对实际叠前海上数据、叠后陆地数据以及叠后复杂陆地数据进行去噪,并与常规的去噪算法如小波变换去噪、双树复小波变换去噪、曲波变换去噪进行比较。实验中训练样本集采用与第 2.4 节相同的数据集进行 CNN 训练。如果待去噪地震数据的噪声水平(事先预估)发生变化,需要重新训练 CNN 网络。

3.1 实际叠前海上地震数据随机噪声去除

在南海某地采集的原始含噪叠前海上数据如图 5a 所示。该数据共 240 道,单道含 800 个采样点,经过预处理已去掉了除随机噪声以外的所有噪声,且幅值已归一化至 $[0,1]$ 。从图中可看到,虽然不含有其它噪声,但双曲反射同相轴被随机噪声严重覆盖。首先对地震数据进行噪声水平估计,然后分别采用 4 种算法对其去噪,去噪效果如图 5b 到图 5e 所示,图 5f 为 CNN 输出的随机噪声。

由图 5b 到图 5e 可看出,小波变换去噪后的地震数据仍然有噪声残留,同相轴模糊。与小波变换去噪相比,双树复小波变换与曲波变换的去噪效果要好一些,同相轴更加清晰,但是局部仍残留有少量噪声。与上述 3 种算法相比,采用本文 CNN 去噪算法去噪后噪声基本无残留,同相轴清晰连贯,更多的局部细节得以保留。

3.2 叠后陆地地震数据随机噪声去除

新疆某地叠后陆地地震剖面中的一段如图 6a




图 5 叠前海上地震数据的不同去噪算法结果对比

a 预处理后的含噪叠前数据; b 小波变换去噪; c 双树复小波变换去噪; d 曲波变换去噪; e CNN 去噪; f CNN 输出的随机噪声

所示。该段剖面数据共 200 道,单道含 600 个采样点,事先已经过预处理去除了噪声。为了定量比较分析各算法的去噪效果,在该段数据中人为添加均值为 0、噪声水平分别为数据幅值 20%,25%,30%的加性

高斯白噪声。其中噪声水平为 20%的含噪数据见图 6b。分别采用 4 种算法对其去噪,去噪效果如图 6c~图 6f 所示。表 1 为 4 种去噪算法的性能指标对比。




图 6 叠后陆地地震数据的不同去噪算法结果对比

a 预处理后的叠后地震数据; b 添加 20%噪声后的数据; c 小波变换去噪; d 双树复小波变换去噪; e 曲波变换去噪; f CNN 去噪

表 1 叠后陆地地震数据的不同去噪算法性能指标对比

噪声水平 σ 和 S_{NR_IN}/dB	去噪算法	S_{NR_OUT}/dB	P_{SNR}/dB	M_{SE}
$\sigma=20\%$ $S_{NR_IN}=8.437\ 5$	小波变换	18.231 9	23.756 7	0.004 2
	双树复小波变换	19.517 4	25.042 2	0.003 1
	曲波变换	23.226 3	28.751 1	0.001 3
	CNN 去噪	24.778 5	30.303 3	0.000 9
$\sigma=25\%$ $S_{NR_IN}=6.499\ 3$	小波变换	17.231 0	22.755 8	0.005 3
	双树复小波变换	18.317 9	23.842 6	0.004 1
	曲波变换	21.987 4	27.512 2	0.001 8
	CNN 去噪	23.231 5	28.756 3	0.001 3
$\sigma=30\%$ $S_{NR_IN}=4.915\ 6$	小波变换	16.515 8	22.040 6	0.006 3
	双树复小波变换	17.452 0	22.976 8	0.005 0
	曲波变换	20.975 1	26.499 9	0.002 2
	CNN 去噪	22.074 2	27.599 0	0.001 7

由图 6c~图 6f 可见, CNN 去噪算法的效果要明显优于小波变换与双树复小波变换去噪。与曲波变换相比,二者均有良好的去噪效果,但 CNN 去噪后的剖面上同相轴更清晰。

表 1 更加直观展现了 4 种去噪算法的去噪性能。在不同的噪声水平 σ 下,本文 CNN 去噪算法的 S_{NR_OUT} 和 P_{SNR} 最大且 M_{SE} 最小,这意味着 CNN 去噪能力最强,接下来依次是曲波变换、双树复小波变换

和小波变换。

3.3 叠后复杂陆地地震数据随机噪声去除

图 7a 为新疆某地原始含噪叠后地震剖面中的一段。该段数据共 200 道,单道含 450 个采样点,已经过预处理去掉了除随机噪声以外的噪声。首先对地震数据进行噪声水平估计,然后分别采用 4 种算法对其去噪,去噪效果如图 7b~图 7e 所示,图 7f 为 CNN 输出的随机噪声。




图 7 叠后复杂陆地地震数据的不同去噪算法结果对比

a 预处理后的含噪叠后数据; b 小波变换去噪; c 双树复小波变换去噪; d 曲波变换去噪; e CNN 去噪; f CNN 去除的随机噪声

对比图 7b,图 7c,图 7d 和图 7e 可看出,4 种去噪算法都有一定去噪效果,但小波变换和双树复小波变换去噪后的地震数据仍有噪声残留,且靠近同相轴区域比较明显。CNN 去噪与曲波变换去噪效果相比于前 2 种算法有了较大改善,剖面上已无明显噪声残留。但曲波变换去噪的结果过于平滑,波动特征损失较多。而 CNN 去噪局部细节保留得更完整,同相轴清晰,整个剖面显得干净。

4 结论

为了更有效地去除地震数据的随机噪声,本文提出了一种基于深度学习卷积神经网络(CNN)的地震数据随机噪声去除算法,是将深度学习用于地震信号处理的一种尝试。算法的关键在于构建一个适合于地震数据去噪的 CNN,该 CNN 由输入层、卷积层、

激活层、归一化层、输出层等构成,采用残差学习方式,辅之以 ReLU 和 BN 归一化,使得 CNN 的训练精度较高,保留了更多的原始数据细节。地震数据去噪实验表明:CNN 能有效去除地震数据随机噪声,无论是从主观定性还是客观定量方面衡量,与常规地震数据去噪算法如小波变换、双树复小波变换以及曲波变换等相比,具有更强的去噪性能。下一步的工作是探讨 CNN 的地震数据去噪计算效率,分析 CNN 去噪时的泛化能力,探索更有效的训练样本集构建方式,并尝试用 CNN 去除面波和多次折射波等非随机噪声。

参 考 文 献

- [1] 张军华,吕宁,田连玉,等.地震资料去噪方法综合评述[J].石油地球物理勘探,2005,40(增刊1):121-127
ZHANG J H, LV N, TIAN L Y, et al. A comprehensive review of seismic data denoising methods[J]. Oil Geophysical Prospecting, 2005, 40(S1): 121-127
- [2] CLARK C, STORKEY A. Training deep convolutional neural networks to play go[J]. Proceedings of the 32th International Conference on Machine Learning (ICML-15), 2015: 1766-1774
- [3] LV Z H, SONG H B, JO M. Guest editorial: recent advances in network big data analysis[J]. IEEE Transactions on Industrial Informatics, 2017, 99(1): 1-1
- [4] 中原敏明,山崎乔.对地震记录作 $f-k$ 二维滤波[J].石油物探,1974,26(1):73-86
ZHONG YUAN M M, SHAN Q Q. $F-k$ two-dimensional filtering for seismic records [J]. Geophysical Prospecting for Petroleum, 1974, 26(1): 73-86
- [5] 康冶,于承业,贾卧,等. $f-x$ 域去噪方法研究[J].石油地球物理勘探,2003,38(2):136-138
KANG Y, YU C Y, JIA W, et al. A study on noise-suppression method in $f-x$ domain [J]. Oil Geophysical Prospecting, 2003, 38(2): 136-138
- [6] 刘婷婷,陈阳康. $f-x$ 域经验模式分解与多道奇异谱分析相结合去除随机噪声[J].石油物探,2016,55(1):67-75
LIU T T, CHEN Y K. Random noise attenuation based on EMD and MSSA in $f-x$ domain [J]. Geophysical Prospecting for Petroleum, 2016, 55(1): 67-75
- [7] 张华,陈小宏,杨海燕.地震信号去噪的最优小波基选取方法[J].石油地球物理勘探,2011,46(1):70-75
ZHANG H, CHEN X H, YANG H Y. Optimistic wavelet basis selection in seismic signal noise elimination [J]. Oil Geophysical Prospecting, 2011, 46(1): 70-75
- [8] 王姣,李振春,王德营.基于 CEEMD 的地震数据小波阈值去噪方法研究[J].石油物探,2014,53(2):164-172
WANG J, LI Z C, WANG D Y. A method for wavelet threshold denoising of seismic data based on CEEMD [J]. Geophysical Prospecting for Petroleum, 2014, 53(2): 164-172
- [9] LI J H, ZHANG Y J, QI R, et al. Wavelet-based higher order correlative stacking for seismic data denoising in the curvelet domain [J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2017, 10(8): 3810-3820
- [10] 孙成禹,邵婕,蓝阳,等.基于独立分量分析基的地震随机噪声压制[J].石油物探,2016,55(2):196-204
SUN C Y, SHAO J, LAN Y, et al. Seismic random noise suppression based on independent component analysis basis functions [J]. Geophysical Prospecting for Petroleum, 2016, 55(2): 196-204
- [11] 刘成明,王德利,王通,等.基于 Shearlet 变换的地震随机噪声压制[J].石油学报,2014,35(4):692-699
LIU C M, WANG D L, WANG T, et al. Random seismic noise attenuation based on the Shearlet transform [J]. Acta Petrolei Sinica, 2014, 35(4): 692-699
- [12] CHEN Y K, ZHOU Y T, CHEN W, et al. Empirical low-rank approximation for seismic noise attenuation [J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 19(1): 1-16
- [13] ZHOU Y T, SHI C J, CHEN H M, et al. Spike-like blending noise attenuation using structural low-rank decomposition [J]. IEEE Geoscience and Remote Sensing Letters, 2017, 14(1): 1-5
- [14] 刘伟,曹思远,崔震.基于压缩感知和 TV 准则约束的地震资料去噪[J].石油物探,2015,54(2):180-187
LIU W, CAO S Y, CUI Z. Random noise attenuation based on compressive sensing and TV rule [J]. Geophysical Prospecting for Petroleum, 2015, 54(2): 180-187
- [15] 吴剑华,吴金枢.一种基于神经网络的地震信号去噪的处理方法[J].西安石油大学学报(自然科学版),1997,12(6):17-20
WU J H, WU J S. A method denoising from seismic data based on nerve network [J]. Journal of Xi'an Shi You University (Natural Science Edition), 1997, 12(6): 17-20
- [16] 张范民,李清河,张元生,等.利用人工神经网络理论对地震信号及地震震相进行识别[J].西北地震学报,1998,20(4):43-49
ZHANG F M, LI Q H, ZHANG Y S, et al. The seismic signal and phase recognition by using artificial neural network theory [J]. Northwestern Seismological Journal, 1998, 20(4): 43-49
- [17] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks [J]. International Conference on Neural Information Processing Systems Curran Associates Inc, 2012: 1097-1105
- [18] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition [J]. Computer Science, 2014: arXiv:1409.1556
- [19] ZHANG K, ZUO W M, CHEN Y J, et al. Beyond a Gaussian denoiser: residual learning of deep CNN for image denoising [J]. IEEE Transactions on Image Processing, 2017, 26(7): 3142-3155

(下转第 877 页)

420

- [7] 李英才,王艳仓,李旭,等.地表一致性俞氏子波反褶积[J].石油物探,1997,36(增刊1):56-62
LI Y C, WANG Y C, LI X, et al. Surface-consistent YU wavelet deconvolution[J]. Geophysical Prospecting for Petroleum, 1997, 36(S1): 55-62
- [8] WANG Y H. A stable and efficient approach of inverse Q filtering[J]. Geophysics, 2002, 67(2): 657-663
- [9] WANG Y H. Inverse Q-filter for seismic resolution enhancement[J]. Geophysics, 2006, 71(3): V51-V60
- [10] WANG Y H, GUO J. Modified Kolsky model for seismic attenuation and dispersion[J]. Journal of Geophysics and Engineering, 2004, 1(4): 187-196
- [11] WANG Y H. Quantifying the effectiveness of stabilized inverse Q filtering[J]. Geophysics, 2003, 68(1): 337-345
- [12] 渥·伊尔马滋.地震资料分析[M].北京:石油工业出版社,2006:213-216
YILMAZ O. Seismic data analysis[M]. Beijing: Petroleum Industry Press, 2006: 213-216
- [13] ZHENG H M, LOU B, JIANG L. Research and application of wave equation forward model[C]// CPS/SEG Beijing 2009 International Geophysical Conference, 2009
- [14] ROBINSON E A, TREITEL S. Principles of digital Wiener filtering[J]. Geophysical Prospecting, 1967, 15(1): 311-333
- [15] 王成彬.准噶尔盆地南缘山前带激发因素分析[J].勘探地球物理进展,2008,31(1):59-64
WANG X B. Discussion on shooting factors in the foothill in southern Junggar basin[J]. Progress in Exploration Geophysics, 2008, 31(1): 55-62
- [16] 李庆忠.从信噪比谱分析看滤波及反褶积的效果[J].石油地球物理勘探,1986,21(6):575-601
LI Q Z. The evaluation of filter and deconvolution effects by S/N spectrum analysis[J]. Oil Geophysical Prospecting, 1986, 21(6): 575-601
- [17] 杨学亭,刘财,刘洋,等.基于连续小波变换的时频域地震波能量衰减补偿[J].石油物探,2014,53(5):523-529
YANG X T, LIU C, LIU Y, et al. The attenuation compensation of seismic wave in time-frequency domain based on the continuous wavelet transform[J]. Geophysical Prospecting for Petroleum, 2014, 53(5): 523-529
- [18] 王小杰,栾锡武.基于小波分频技术的地层Q值补偿方法研究[J].石油物探,2017,56(2):203-209
WANG X J, LUAN X W. The study of formation Q value compensation method based on wavelet frequency division technology[J]. Geophysical Prospecting for Petroleum, 2017, 56(2): 203-209
- [19] 张文,周志才,于承业.一种改进的近地表强吸收补偿方法研究[J].石油物探,2017,56(2):210-215
ZHANG W, ZHOU Z C, YU C Y. An improved compensation method for near surface strong absorption[J]. Geophysical Prospecting for Petroleum, 2017, 56(2): 210-215

(编辑:朱文杰)

(上接第869页)

- [20] HOOMOD H K, DAWOOD S H. Fast image denoising based on modify CNN and noise estimation[J]. Annual Conference on New Trends in Information & Communications Technology (NTICT) Applications, 2017: 280-285
- [21] HE Z L, ZHANG J, KAN M N, et al. Robust FEC-CNN: a high accuracy facial landmark detection system[J]. The IEEE Conference on Computer Vision and Pattern Recognition (CVPR) Workshops, 2017: 98-104
- [22] SWIETOJANSKI P, GHOSH A, RENALS S. Convolutional neural networks for distant speech recognition[J]. IEEE Signal Processing Letters, 2014, 21(9): 1120-1124
- [23] IOFFE S, SZEGEDY C. Batch normalization: accelerating deep network training by reducing internal covariate shift[J]. International Conference on Machine Learning, 2015: 448-456
- [24] SOKOLIĆ J, GIRYES R, SAPIRO G, et al. Robust large margin deep neural networks[J]. IEEE Transactions on Signal Processing, 2017, 65(16): 4265-4280
- [25] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition[J]. IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778
- [26] CHILIMBI T, SUZUE Y, APACIBLE J, et al. Project adam: building an efficient and scalable deep learning training system[J]. USENIX Symposium on Operating Systems Design and Implementation, 2014: 571-582
- [27] VEDALDI A, LENC K. Matconvnet: convolutional neural networks for matlab[J]. Proceedings of the 23rd Annual ACM Conference on Multimedia Conference, 2015: 689-692
- [28] KIM H, NAM H, JUNG W, et al. Performance analysis of CNN frameworks for GPUs[J]. IEEE International Symposium on Performance Analysis of Systems and Software (ISPASS), 2017: 55-64

(编辑:朱文杰)